

Reconocimiento de emociones en la voz

Análisis exploratorio del corpus RAVDESS (habla)

Saúl Ubaldo Rojas Vázquez Karols Cisneros Mónica

2 de octubre de 2026

Objetivos

Objetivo general

Caracterizar el corpus RAVDESS (habla) para fundamentar un modelo de clasificación de emociones a partir de la voz.

Objetivos específicos

1. Publicar el corpus en Supabase para consumirlo sin copias locales.
2. Verificar la integridad y la calidad de los datos.
3. Describir su composición por emoción, intensidad, género y actor.
4. Identificar los descriptores acústicos que distinguen emociones.
5. Detectar fuentes de variación ajenas a la emoción.

Dataset: RAVDESS

- **24 actores** profesionales (12 H / 12 M)
- **8 emociones:** neutral, calma, alegría, tristeza, enojo, miedo, asco, sorpresa
- 2 intensidades, 2 frases, 2 repeticiones
- Subconjunto de **audio de habla:**
1440 WAV, 48 kHz, 590.3 MB

Frases: "Kids are talking by the door" /
"Dogs are sitting by the door".

Metadatos en el nombre del archivo

03-01-05-02-01-01-07.wav

03	solo audio
01	habla
05	enojo
02	intensidad fuerte
01	frase "Kids"
01	repetición 1
07	actor 7 (impar = hombre)

Datos en Supabase

Storage — bucket ravedess-audio

- 1440 WAV en
Actor_XX/<archivo>.wav
- Lectura pública por URL

PostgreSQL — tabla ravedess_clips

- Una fila por clip: actor, género, emoción, intensidad, frase, duración, etc.
- RLS activo: solo lectura para roles públicos

Verificación de la carga



1440 objetos = 1440 filas

0 archivos faltantes

Tamaño idéntico a la fuente

Los notebooks leen la tabla vía API REST y descargan el audio bajo demanda a una caché temporal.


Calidad y composición



- Sin nullos ni duplicados
- 5 clips estéreo → mono
- 60 clips por actor; 720 por género
- **Neutral: 96 vs. 192** (sin intensidad fuerte)

Frame length y hop length

Efecto de frame/hop length (actor 03, enojo, intensidad fuerte)





MFCC, ZCR y RMS se calculan **cuadro a cuadro**.

Frame	Hop	ms	ms	Cuadros
512	128	23.2	5.8	431
1024	256	46.4	11.6	216
2048	512	92.9	23.2	108
4096	1024	185.8	46.4	54


Elegido: 2048/512 (92.9/23.2 ms).
512 da curvas ruidosas y 4096 borra los picos silábicos.

Duración y silencios



Clips de 2.9–5.3 s; **49.8 % es silencio** (0.937 s al inicio, 0.893 s al final). Voz efectiva: 1.9 s.


Waveplot por emoción y género



- Misma frase: actor 04 (mujer) y actor 03 (hombre)
- Enojo, alegría y miedo: mayor amplitud y ataques abruptos
- Neutral y calma: baja energía
- Asco cambia entre hablantes


Envolvente de energía (todos los clips)

Envolvente de energía RMS por emoción (todos los clips)




La voz inicia en ≈ 1 s. **Enojo** tiene el ataque y la energía más altos; asco es la emisión más larga.

Misma frase, ocho emociones



Enojo, alegría y miedo: más energía en altas frecuencias y armónicos más espaciados (tono más agudo).

Descriptores acústicos por emoción





¿Qué descriptor distingue mejor?

Kruskal–Wallis entre 8 emociones

Descriptor	H	p	ε^2
Energía RMS media	645.5	$< 10^{-10}$	0.446
Duración de voz (s)	296.0	$< 10^{-10}$	0.202
F0 media (Hz)	290.9	$< 10^{-10}$	0.198
Centroide espectral (Hz)	248.3	$< 10^{-10}$	0.169
Rango de F0 p5–p95 (Hz)	239.7	$< 10^{-10}$	0.162
Tasa de cruces por cero	174.4	$< 10^{-10}$	0.117

- **Energía:** enojo 0.037 vs. calma 0.004
- **F0:** miedo 270.7 Hz vs. calma 160.5 Hz
- Ningún descriptor separa solo las 8 clases


Género e intensidad



F0 mediana: **149.3 Hz (H) vs. 256.9 Hz (M)**, una diferencia mayor que entre emociones.
La intensidad fuerte multiplica la energía por **2.6**.

Valores atípicos por género (regla IQR)

Valores atípicos por género (regla IQR, en rojo)



	Mujeres		Hombres	
	<i>n</i>	%	<i>n</i>	%
ZCR	11	1.5 %	17	2.4 %
RMS	75	10.4 %	75	10.4 %
MFCC1	0	0.0 %	1	0.1 %
MFCC2	13	1.8 %	9	1.2 %
MFCC3	12	1.7 %	3	0.4 %
MFCC4	9	1.2 %	6	0.8 %

$n = 720$ clips por género.

¿De dónde vienen los atípicos?


Atípicos por emoción — mujeres								Atípicos por emoción — hombres									
ZCR	0	0	0	2	1	4	4	0	-	0	5	0	4	1	1	6	0
RMS	0	0	11	1	33	27	0	3	-	0	0	6	0	51	17	0	1
MFCC1	0	0	0	0	0	0	0	0	-	0	0	0	1	0	0	0	0
MFCC2	0	0	1	2	4	6	0	0	-	0	0	0	0	4	3	2	0
MFCC3	0	0	6	0	1	5	0	0	-	0	0	0	0	2	1	0	0
MFCC4	0	0	1	0	0	8	0	0	-	0	0	1	0	3	1	0	1
	neutral	calma	alegría	tristeza	enojo	miedo	asco	sorpresa		neutral	calma	alegría	tristeza	enojo	miedo	asco	sorpresa

Los atípicos de RMS vienen de **enojo, miedo y alegría** con intensidad fuerte: son **señal, no ruido**.

⇒ conservarlos y usar escalas robustas (log, cuantiles).

Patrones por emoción: mujeres


Perfil acústico por emoción — mujeres (Min-Max entre emociones)



Media por emoción, Min-Max entre emociones dentro del género.


Patrones por emoción: hombres

Perfil acústico por emoción — hombres (Min-Max entre emociones)




Perfiles casi iguales a los de mujeres. **Enojo**: energía; **miedo/sorpresa**: tono; **asco**: ZCR alta con energía baja.

Perfil MFCC y redundancia




MFCC1 $\approx$ energía ($\rho = 0.97$). Los MFCC 2–6 separan activación baja (+) de alta (-).



Estructura global (PCA)


PCA (PC1 29%, PC2 14% de la varianza)




PC1 (29.2 %) funciona como un **eje de activación**; se necesitan 15 componentes para el 90 % de la varianza.

El hablante domina sobre la emoción

t-SNE de los descriptores acústicos



t-SNE por género



En t-SNE, las emociones se mezclan, mientras que el **género** forma dos regiones casi disjuntas.

Resultados del análisis exploratorio

1. **Datos limpios y completos:** 1440 clips; solo hay que convertir a mono y recortar silencios (≈ 50 % del clip).
2. **Balance:** perfecto por actor y género; neutral tiene la mitad de muestras. $\Rightarrow$ métricas macro y pesos por clase.
3. **Señal emocional:** energía, F0, duración y centroide difieren significativamente y describen sobre todo un eje de *activación*.
4. **Atípicos:** concentrados en la energía (≈ 10 %), propios de las emociones de alta activación $\Rightarrow$ conservarlos.
5. **Radar:** perfiles por emoción compartidos entre géneros una vez normalizados.
6. **Confusor principal:** el hablante y su género. $\Rightarrow$ evaluación con actores no vistos, normalización por hablante y aumentación de tono.
7. **Infraestructura:** corpus en Supabase con acceso de solo lectura, reproducible desde cualquier equipo.

Referencias

- S. R. Livingstone y F. A. Russo (2018). The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS). *PLoS ONE* 13(5): e0196391. doi:10.1371/journal.pone.0196391. Licencia CC BY-NC-SA 4.0.
- B. McFee *et al.* (2015). librosa: Audio and music signal analysis in Python. *Proc. SciPy*.
- gemmin. Speech Emotion Recognition 90 %. Kaggle Notebook.