

Reconocimiento de emociones en la voz

Análisis exploratorio del corpus RAVDESS (habla)

Saúl Ubaldo Rojas Vázquez

Karols Cisneros

Mónica

2 de octubre de 2026

Resumen

Se presenta el análisis exploratorio del subconjunto de habla del corpus RAVDESS (1440 grabaciones, 24 actores, 8 emociones) como etapa previa a la construcción de un clasificador de emociones a partir de la señal de voz. Los datos se alojaron en Supabase (Storage + PostgreSQL) para consumirlos sin mantener copias locales. Se verificó la calidad de los datos, se caracterizó la composición del corpus y se extrajeron 30 descriptores acústicos por clip (energía, tasa de cruces por cero, centroide y *roll-off* espectral, frecuencia fundamental y MFCC). Todos los descriptores difieren significativamente entre emociones (Kruskal–Wallis, $p < 10^{-10}$); la energía RMS es el más discriminante ($\epsilon^2 = 0.446$). Los valores atípicos se concentran en la energía (≈ 10 % de los clips por género) y provienen de emociones de alta activación, y los gráficos de radar muestran perfiles por emoción muy parecidos en mujeres y hombres. Sin embargo, las proyecciones en baja dimensión muestran que la estructura dominante de los datos corresponde al *hablante* (en particular a su género) y no a la emoción, lo que condiciona el diseño del modelo y su protocolo de evaluación.

1. Introducción y objetivos

El reconocimiento automático de emociones en la voz (*Speech Emotion Recognition*, SER) busca inferir el estado afectivo de un hablante a partir de propiedades acústicas de su señal, como la intensidad, el tono o el timbre. Como referencia para la etapa de modelado se toma el enfoque de [3], basado en MFCC, ZCR y energía con una red convolucional 1D. Antes de entrenar un modelo es necesario entender qué contiene el corpus, qué tan balanceado está y qué propiedades acústicas separan realmente a las emociones.

Objetivo general. Caracterizar el corpus RAVDESS (habla) para fundamentar el diseño de un modelo de clasificación de emociones a partir de la voz.

Objetivos específicos.

1. Publicar el corpus en Supabase para su consumo remoto, sin depender de archivos locales.
2. Verificar la integridad y la calidad de los datos (duplicados, formatos, canales, duraciones).
3. Describir la composición del corpus por emoción, intensidad, género y actor.
4. Extraer descriptores acústicos interpretables y evaluar cuáles distinguen entre emociones.
5. Identificar fuentes de variación ajenas a la emoción (hablante, género, intensidad) que deban controlarse durante el modelado.

2. Dataset

2.1. Descripción

RAVDESS (*Ryerson Audio-Visual Database of Emotional Speech and Song*) [1] contiene grabaciones de 24 actores profesionales (12 hombres y 12 mujeres) con acento norteamericano neutro. Se usó la copia publicada en Kaggle ([orville/ravdess-dataset](#)), que incluye audio y video de habla y canto (≈ 24 GB). Para este trabajo se tomó únicamente el **audio de habla** (`Audio_Speech_Actors_01-24`): 1440 archivos WAV a 48 kHz y 16 bits, 590.3 MB.

Cada actor pronuncia dos frases léxicamente neutras, “*Kids are talking by the door*” y “*Dogs are sitting by the door*”, con ocho emociones: neutral, calma, alegría, tristeza, enojo, miedo, asco y sorpresa. Todas salvo neutral se graban con intensidad normal y fuerte, y cada combinación se repite dos veces, es decir, $2 \times 2 \times (7 \times 2 + 1) = 60$ clips por actor.

2.2. Codificación de los archivos

Los metadatos están codificados en el nombre del archivo, `MM-CC-EE-II-SS-RR-AA.wav` (Tabla 1). Por ejemplo, `03-01-05-02-01-01-07.wav` es audio de habla, enojo, intensidad fuerte, frase “Kids”, primera repetición, actor 7 (hombre).

Tabla 1: Campos del nombre de archivo de RAVDESS.

Campo	Código	Valores
Modalidad	MM	01 audio-video, 02 solo video, 03 solo audio
Canal vocal	CC	01 habla , 02 canto
Emoción	EE	01 neutral, 02 calma, 03 alegría, 04 tristeza, 05 enojo, 06 miedo, 07 asco, 08 sorpresa
Intensidad	II	01 normal, 02 fuerte (neutral solo tiene normal)
Frase	SS	01 “Kids are talking by the door”, 02 “Dogs are sitting by the door”
Repetición	RR	01, 02
Actor	AA	01-24; impar = hombre, par = mujer

2.3. Almacenamiento en Supabase

Para no depender de copias locales, el corpus se publicó en el proyecto Supabase `ser-voz-emocional`:

- **Storage:** bucket público `ravdess-audio` con los 1440 WAV, organizados como `Actor_XX/<archivo>.wav`.
- **Base de datos:** tabla `public.ravdess_clips` con una fila por clip (nombre, ruta en Storage, actor, género, emoción, intensidad, frase, repetición, tamaño, frecuencia de muestreo, canales y duración).
- **Seguridad:** *Row Level Security* activo; los roles públicos solo tienen permiso de lectura. Los permisos de escritura usados durante la carga se eliminaron al terminar.

Tras la carga se verificó que los 1440 objetos de Storage coinciden uno a uno con las filas de la tabla y que el tamaño total coincide con el de la fuente. Los notebooks leen los metadatos vía la API REST y descargan los audios bajo demanda a una caché temporal.

3. Metodología del análisis exploratorio

1. **Calidad de datos:** búsqueda de duplicados y nulos; revisión de frecuencia de muestreo, número de canales y duración.

2. **Preprocesamiento:** remuestreo a 22 050 Hz, conversión a mono y recorte de silencios iniciales y finales (umbral de 30 dB bajo el pico).
3. **Parámetros de cuadro:** *frame length* de 2048 muestras (92.9 ms) y *hop length* de 512 muestras (23.2 ms), justificados en la Sección 3.1.
4. **Descriptores por clip** (sobre la señal sin silencios): energía RMS (media y desviación), tasa de cruces por cero (ZCR), centroide y *roll-off* espectral, frecuencia fundamental F0 estimada con pYIN (media, desviación y rango p5–p95), fracción de cuadros sonoros y 20 MFCC promediados en el tiempo [2].
5. **Pruebas estadísticas:** Kruskal–Wallis entre las ocho emociones con tamaño de efecto $\varepsilon^2 = (H - k + 1)/(n - k)$; comparación de medianas por género e intensidad.
6. **Valores atípicos:** regla IQR ($x < Q_1 - 1.5 \text{ IQR}$ o $x > Q_3 + 1.5 \text{ IQR}$) sobre ZCR, RMS y MFCC 1–4, con cuartiles calculados dentro de cada género.
7. **Patrones por emoción:** gráficos de radar con la media de cada descriptor por emoción, normalizada con Min-Max entre emociones dentro de cada género.
8. **Proyecciones:** PCA y t-SNE sobre los descriptores estandarizados.

3.1. Longitud de cuadro y salto

Las tres familias de características que usa el modelo de referencia [3] (MFCC, ZCR y RMS) se extraen con librosa [2] cuadro a cuadro. Antes hay que fijar dos parámetros: el *frame length*, que es el número de muestras de cada cuadro, y el *hop length*, que es cuánto avanza la ventana entre un cuadro y el siguiente. Cuadros más largos mejoran la resolución en frecuencia pero suavizan los cambios rápidos; un salto menor da más resolución temporal a cambio de más cuadros.

La Tabla 2 y la Figura 1 comparan cuatro combinaciones con 75 % de traslape. Con 512 muestras (23 ms) la ZCR es muy ruidosa. Con 4096 (186 ms) se pierden los picos de energía de cada sílaba. La combinación 2048/512 (92.9/23.2 ms) conserva la forma silábica de la envolvente con curvas estables. Además es el valor por defecto de librosa y el que usa la referencia, y produce 108 cuadros en una ventana de 2.5 s.

Tabla 2: Combinaciones de *frame length* y *hop length* evaluadas (22 050 Hz).

Frame (muestras)	Hop (muestras)	Ventana (ms)	Salto (ms)	Cuadros en 2.5 s
512	128	23.2	5.8	431
1024	256	46.4	11.6	216
2048	512	92.9	23.2	108
4096	1024	185.8	46.4	54


Efecto de frame/hop length (actor 03, enojo, intensidad fuerte)

Figura 1: RMS y ZCR cuadro a cuadro de un mismo clip con distintas longitudes de cuadro; la línea gruesa es la combinación elegida.

4. Resultados del análisis exploratorio

4.1. Calidad de los datos

No hay valores nulos ni archivos duplicados, y los 1440 archivos esperados por el diseño factorial están presentes. Todos están muestreados a 48 kHz, pero 5 clips están en estéreo, por lo que se convierten a mono durante la carga. La duración de los clips va de 2.9 a 5.3 s (media 3.7 s).

4.2. Composición del corpus

El diseño es perfectamente balanceado por actor (60 clips cada uno) y por género (720 clips por género). La única asimetría está en la emoción neutral, que tiene 96 clips frente a 192 del resto, porque no se graba con intensidad fuerte (Figura 2). Esto genera un desbalance moderado de 1:2 que debe considerarse al entrenar (pesos por clase o métricas macro) y al interpretar la exactitud por clase.




Figura 2: Número de clips por emoción y su desglose por intensidad. Neutral solo tiene intensidad normal.

4.3. Duración y silencios

En promedio, cerca de la mitad de cada clip (49.8 %) es silencio: 0.937 s al inicio y 0.893 s al final. La voz efectiva dura 1.9 s en promedio. Las emociones difieren ligeramente en duración:

asco produce las emisiones más largas y sorpresa las más cortas (Figura 3). Por ello conviene recortar silencios o usar una ventana fija alineada con la voz antes de extraer características, ya que de lo contrario el modelo aprende sobre segmentos vacíos.




Figura 3: Duración total del clip y duración de la voz tras recortar silencios, por emoción.

4.4. Forma de onda (*waveplot*) y espectrograma

La Figura 4 muestra el *waveplot* de la misma frase para cada emoción, dicha por una mujer (actor 04) y un hombre (actor 03). En ambos, enojo, alegría y miedo tienen mayor amplitud y envolventes más abruptas, mientras que neutral y calma son de baja energía. Asco varía entre hablantes: la actriz lo produce con más energía que el actor. En los espectrogramas (Figura 6), las emociones de alta activación concentran más energía en frecuencias altas y muestran armónicos más espaciados, es decir, un tono más agudo.






Figura 4: Waveplot por emoción y género: frase “Kids are talking by the door”, repetición 1, intensidad fuerte (normal en neutral).

Para ver el patrón más allá de un solo hablante, la Figura 5 resume la envolvente RMS de los 1440 clips. La voz empieza alrededor del segundo 1 en todas las emociones, lo que confirma el silencio inicial. Enojo tiene un ataque marcado al inicio de la frase y la energía más alta durante toda la emisión, seguido por miedo y alegría. Neutral, calma y tristeza quedan por debajo de la mediana global. Asco se extiende hasta cerca del segundo 3, mientras que sorpresa termina antes.


Envolvente de energía RMS por emoción (todos los clips)**Figura 5:** Envolvente RMS por emoción: mediana (línea) y rango intercuartílico (banda) de todos los clips; la línea punteada es la mediana global.**Figura 6:** Espectrogramas mel por emoción (actor 03).

4.5. Descriptores acústicos por emoción

La Tabla 3 y la Figura 7 resumen los descriptores principales. La energía RMS es la variable que más cambia: enojo alcanza una mediana de 0.037 frente a 0.004 en calma. La F0 media sigue un patrón similar, más alta en miedo (270.7 Hz) y más baja en calma (160.5 Hz). El centroide espectral separa a las emociones de alta activación (enojo, miedo, asco) de las de baja activación (neutral, calma).

Tabla 3: Mediana de los descriptores por emoción (señal sin silencios).

Emoción	Dur. voz (s)	RMS	ZCR	Centroide (Hz)	F0 (Hz)
neutral	1.63	0.006	0.104	2056	177
calma	1.95	0.004	0.114	2220	161
alegría	1.72	0.019	0.113	2250	239
tristeza	1.82	0.007	0.116	2192	203
enojo	1.89	0.037	0.140	2544	262
miedo	1.68	0.024	0.125	2527	271
asco	2.04	0.010	0.138	2476	199
sorpresa	1.60	0.016	0.122	2407	265

**Figura 7:** Distribución de seis descriptores acústicos por emoción.

Según la prueba de Kruskal–Wallis, los seis descriptores difieren significativamente entre emociones (Tabla 4). El tamaño de efecto indica que la energía (Energía RMS media, $\varepsilon^2 = 0.446$) es el descriptor más informativo, seguido de la duración y la F0. La ZCR es el menos informativo ($\varepsilon^2 = 0.117$). Aun así, ningún descriptor separa por sí solo las ocho clases: las distribuciones se traslapan ampliamente.

Tabla 4: Prueba de Kruskal–Wallis entre las ocho emociones ($n = 1440$, $k = 8$).

Descriptor	H	p	ε^2
Energía RMS media	645.5	$< 10^{-10}$	0.446
Duración de voz (s)	296.0	$< 10^{-10}$	0.202
F0 media (Hz)	290.9	$< 10^{-10}$	0.198
Centroide espectral (Hz)	248.3	$< 10^{-10}$	0.169
Rango de F0 p5–p95 (Hz)	239.7	$< 10^{-10}$	0.162
Tasa de cruces por cero	174.4	$< 10^{-10}$	0.117

4.6. Efecto del género y de la intensidad

La F0 está dominada por el género del hablante: la mediana es de 149.3 Hz en hombres y 256.9 Hz en mujeres (Figura 8, izquierda). Esta diferencia es mayor que la que existe entre la

mayoría de las emociones, de modo que un umbral fijo de tono confundiría género con emoción. La intensidad fuerte multiplica la energía mediana por 2.6 (0.009 frente a 0.023), con el efecto más marcado en enojo, alegría y miedo (Figura 8, derecha).




Figura 8: Izquierda: F0 media por emoción y género. Derecha: energía RMS por emoción e intensidad.

4.7. Valores atípicos por género

Siguiendo la regla IQR por género (720 clips de mujeres y 720 de hombres), la Tabla 5 muestra que la energía RMS concentra la mayoría de los valores atípicos: $\approx 10\%$ de los clips en ambos géneros. El resto de los descriptores no pasa de 2.5% , y MFCC1 prácticamente no tiene atípicos.

Tabla 5: Valores atípicos (regla IQR) por descriptor y género.

Descriptor	Mujeres ($n = 720$)		Hombres ($n = 720$)	
	Atípicos	%	Atípicos	%
ZCR	11	1.5 %	17	2.4 %
RMS	75	10.4 %	75	10.4 %
MFCC1	0	0.0 %	1	0.1 %
MFCC2	13	1.8 %	9	1.2 %
MFCC3	12	1.7 %	3	0.4 %
MFCC4	9	1.2 %	6	0.8 %

Valores atípicos por género (regla IQR, en rojo)




Figura 9: Distribución de cada descriptor por género; en rojo, los valores atípicos.

La Figura 10 muestra de qué emociones provienen. Los atípicos de RMS son casi todos de enojo, miedo y alegría, es decir, clips de alta activación con intensidad fuerte. Por lo tanto, **no son errores de medición sino el extremo legítimo de esas emociones**, y eliminarlos quitaría justamente los ejemplos más característicos. Conviene conservarlos y usar transformaciones robustas, como el logaritmo de la energía o el escalado por cuantiles. La distribución de RMS es muy asimétrica, con una cola larga a la derecha.

Atípicos por emoción — mujeres								Atípicos por emoción — hombres								
ZCR	0	0	0	2	1	4	4	0	0	5	0	4	1	1	6	0
RMS	0	0	11	1	33	27	0	3	0	0	6	0	51	17	0	1
MFCC1	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
MFCC2	0	0	1	2	4	6	0	0	0	0	0	0	4	3	2	0
MFCC3	0	0	6	0	1	5	0	0	0	0	0	0	2	1	0	0
MFCC4	0	0	1	0	0	8	0	0	0	0	1	0	3	1	0	1
	neutral	calma	alegría	tristeza	enojo	miedo	asco	sorpresa	neutral	calma	alegría	tristeza	enojo	miedo	asco	sorpresa

Figura 10: Número de valores atípicos por descriptor y emoción, para cada género.

4.8. Patrones por emoción y género (gráficos de radar)

Los gráficos de radar (Figuras 11 y 12) muestran el perfil medio de cada emoción en ocho descriptores. Se normalizan con Min-Max dentro de cada género, de modo que 0 corresponde a la emoción con el valor más bajo y 1 a la más alta. Esto elimina la diferencia absoluta de tono entre mujeres y hombres y permite comparar la *forma* de los perfiles.

- **Baja activación** (neutral, calma, tristeza): RMS bajo y F0 y centroide bajos o intermedios, con el peso puesto en MFCC 2–4, es decir, un espectro con menos energía en frecuencias altas.
- **Enojo**: máximo en RMS y MFCC1 y valores altos en ZCR y centroide, en ambos géneros; es el perfil más extremo.

- **Miedo:** F0 y centroide altos. En mujeres además es muy energético (RMS 0.80 frente a 0.40 en hombres).
- **Asco:** la ZCR más alta con energía baja. Este patrón sugiere una voz más ruidosa o fricativa, no más fuerte, y es el que más distingue a asco del resto.
- **Alegría y sorpresa:** F0 alta con energía intermedia. Su parecido explica que se confundan entre sí.

Los perfiles son muy similares entre géneros. Esto indica que, una vez descontado el tono propio del hablante, los patrones emocionales son compartidos, lo que respalda normalizar por hablante.

Perfil acústico por emoción — mujeres (Min-Max entre emociones)




Figura 11: Perfil acústico por emoción, mujeres (media por emoción normalizada con Min-Max).

Perfil acústico por emoción — hombres (Min-Max entre emociones)




Figura 12: Perfil acústico por emoción, hombres (media por emoción normalizada con Min-Max).

4.9. Perfil MFCC

Los MFCC describen la envolvente espectral, es decir, el timbre. El primer coeficiente sigue a la energía ($\rho = 0.97$ con la RMS): es alto en enojo y bajo en calma, neutral y tristeza. Los coeficientes 2 a 6 distinguen a las emociones de baja activación, con valores positivos en neutral y calma, de las de alta activación, con valores negativos en enojo y miedo. Los coeficientes de orden alto (15–20) aportan menos contraste, salvo en miedo (Figura 13).




Figura 13: Media estandarizada (z) de cada coeficiente MFCC por emoción.

4.10. Redundancia entre descriptores

Varios descriptores son casi redundantes (Figura 14): RMS y MFCC1 ($\rho = 0.97$), centroide y *roll-off* ($\rho = 0.93$), desviación y rango de F0 ($\rho = 0.99$), y ZCR y centroide ($\rho = 0.87$). Por ello conviene usar regularización o reducción de dimensión al combinar descriptores agregados.




Figura 14: Correlación de Spearman entre descriptores.

4.11. Estructura global: emoción frente a hablante

En el PCA (Figura 15), las dos primeras componentes explican 29.2 % y 13.5 % de la varianza, y se requieren 15 componentes para alcanzar el 90 %. La primera componente actúa como un eje de *activación*: neutral, calma y tristeza se ubican de un lado, y enojo, miedo y alegría del otro. Aun así, el traslape entre emociones es considerable.

PCA (PC1 29%, PC2 14% de la varianza)




Figura 15: PCA de los descriptores; cada panel resalta una emoción sobre el resto (gris).

El t-SNE confirma este traslape: las emociones no forman grupos compactos (Figura 16). En cambio, el mismo mapa coloreado por género muestra dos regiones casi disjuntas (Figura 17). Por tanto, **la variación entre hablantes domina sobre la variación emocional** en el espacio de descriptores.

t-SNE de los descriptores acústicos




Figura 16: t-SNE de los descriptores acústicos; cada panel resalta una emoción.




Figura 17: El mismo t-SNE coloreado por género del hablante.

5. Conclusiones

1. El corpus está completo y es limpio: 1440 clips sin duplicados ni nulos. Solo requiere convertir 5 clips estéreo a mono y recortar silencios, que ocupan ≈ 50 % de cada clip.
2. Está balanceado por actor y género. La clase neutral tiene la mitad de muestras que el resto, por lo que conviene reportar métricas macro y considerar pesos por clase.
3. Energía, F0, duración y centroide espectral difieren significativamente entre emociones. Juntos describen sobre todo un eje de activación (alta frente a baja). Las emociones con activación similar, como enojo y alegría o calma y neutral, son las que más se traslapan.
4. Los valores atípicos (regla IQR) se concentran en la energía, con ≈ 10 % de los clips por género, y provienen de enojo, miedo y alegría con intensidad fuerte. Son señal, no ruido: se recomienda conservarlos y usar escalas robustas.
5. Los gráficos de radar muestran perfiles por emoción casi iguales en mujeres y hombres una vez normalizados. Destacan la energía en enojo, el tono en miedo y sorpresa, y la ZCR en asco.
6. La frame length de 2048 y la hop length de 512 muestras equilibran la resolución temporal y la estabilidad de MFCC, ZCR y RMS, y coinciden con el modelo de referencia.
7. La identidad y el género del hablante son la principal fuente de variación. En consecuencia, la evaluación del modelo debe reservar actores completos para prueba (evaluación independiente del hablante), y conviene normalizar por hablante o aumentar los datos con variaciones de tono.
8. Los datos quedan disponibles en Supabase con acceso público de solo lectura, lo que permite reproducir el análisis desde cualquier equipo sin copias locales.

Referencias

- [1] S. R. Livingstone y F. A. Russo, “The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English”, *PLoS ONE*, 13(5): e0196391, 2018. <https://doi.org/10.1371/journal.pone.0196391>. Licencia CC BY-NC-SA 4.0.

- [2] B. McFee *et al.*, “librosa: Audio and music signal analysis in Python”, en *Proc. 14th Python in Science Conference*, pp. 18–25, 2015.
- [3] gemmin, “Speech Emotion Recognition 90 %”, Kaggle Notebook. <https://www.kaggle.com/code/gemmin/speech-emotion-recognition-90/notebook>.