Reconocimiento de emociones en la voz

Modelo de clasificación sobre el corpus RAVDESS (habla)

Saúl Rojas Karol Cisneros Mónica Gonzalez

November 1, 2026

Problema

Objetivo general

Clasificar la emoción expresada en un audio de voz (8 clases) con una red neuronal convolucional.

Es un problema de clasificación multiclase, no de regresión.

- **Entrada:** un clip de voz de ≈ 4 s.
- **Salida:** una de 8 emociones: neutral, calma, alegría, tristeza, enojo, miedo, asco, sorpresa.
- **Azar:** $1/8 = 12.5\,\%$ de accuracy.

Objetivos específicos

1. Construir un modelo basado en la referencia *Speech Emotion Recognition 90 %*.
2. Evitar la fuga de datos de la referencia (aumentar *después* de dividir).
3. Medir si el modelo generaliza a hablantes que nunca vio.

Datos: RAVDESS (recordatorio del EDA)

- **Origen:** Livingstone y Russo (2018), CC BY-NC-SA 4.0
- **Tamaño:** 1440 WAV, 24 actores (12 H / 12 M), 60 clips por actor
- **Formato:** audio de habla, 48 kHz, con 2 frases en inglés
- **Etiquetas:** salen del nombre del archivo (emoción, intensidad, frase, repetición, actor)
- **Calidad:** sin nulos ni duplicados; 5 clips estéreo $\rightarrow$ mono
- **Balance:** 192 clips por emoción, salvo neutral (96)

Hallazgos del EDA que condicionan el modelo

- **49.8 %** de cada clip es silencio ⇒ solo se usan 2.5 s.
- Energía, F0, duración y centroide difieren por emoción (Kruskal–Wallis, $p < 10^{-10}$), pero **ninguno separa las 8 clases solo**.
- Los atípicos de energía son señal ($\approx$ 10 %) ⇒ se conservan.
- **El hablante domina sobre la emoción:** ⇒ hay que evaluar con actores no vistos.

t-SNE: el género forma dos regiones casi disjuntas.

Modelo: tratamiento de los datos

1. **Recorte:** 2.5 s desde el segundo 0.6, a 22 050 Hz, mono.
2. **Descriptores cuadro a cuadro** (frame 2048, hop 512 $\rightarrow$ 108 cuadros): ZCR, RMS y 20 MFCC.
3. **Vector por clip:** $108 \times (1 + 1 + 20) = \mathbf{2376}$ **valores**.
4. **Aumentación** $\times 3$ (solo entrenamiento): original, + ruido, + cambio de tono (0.7 semitonos) con ruido.
5. **Normalización:** `StandardScaler` ajustado solo con entrenamiento.

Diferencia clave con la referencia

La referencia aumenta antes de dividir: copias ruidosas de un mismo clip caen en entrenamiento y prueba (fuga de datos). Aquí se divide primero.

Modelo: arquitectura (red Conv1D)

Bloque	Filtros	Kernel	Pool	Dropout
1	128	5	5	—
2	128	5	5	0.2
3	64	5	5	—
4	64	3	5	0.2
5	32	3	3	0.2

Cada bloque: Conv1D → ReLU → BatchNorm → MaxPool.

- Entrada: vector de 2376 valores
- 5 bloques convolucionales
- Capa densa de **512** + BatchNorm
- Salida: **8** neuronas (softmax)

Anchos reducidos a 1/4 por entrenar en CPU; con GPU: 512-512-256-256-128.

Modelo: aprendizaje e hiperparámetros

Parámetro	Valor
Optimizador	Adam, lr $= 10^{-3}$
Pérdida	Entropía cruzada
Tamaño de lote	64
Épocas	máx. 50
Early stopping	paciencia 8
Reducción de lr	$\times 0.5$, paciencia 3
lr mínimo	10^{-5}
Semilla	42

- Se monitorea la **accuracy de validación**.
- Al final se recuperan los pesos de la **mejor época**, no los de la última.
- Métricas: accuracy y **F1 macro** (neutral tiene la mitad de clips).

Dos protocolos de evaluación

	A: por actor	**B: al azar por clip**
Entrenamiento	actores 1–18	80 % (estratificado)
Validación	actores 19–20	10 %
Prueba	actores 21–24	10 %
Clips (entr. / val. / prueba)	1080 / 120 / 240	1152 / 144 / 144
Con aumentación $\times 3$	3240	3456

A: hablantes no vistos

¿Reconoce la emoción en personas nuevas? Es la medida más honesta de generalización.

B: mismos hablantes

¿Reconoce la emoción en voces que ya conoce? Es comparable con la referencia, pero sin fuga.

Resultados: protocolo A (actores no vistos)

Accuracy 43.3 % y **F1 macro 0.416** sobre 240 clips (azar: 12.5 %).

Calma se reconoce mejor (78 %); tristeza y miedo casi no (12 % cada una).

Resultados: protocolo B (división al azar)

Accuracy 60.4 % y **F1 macro 0.599** sobre 144 clips (21 épocas).

Mejor que A porque los mismos actores aparecen en entrenamiento y prueba.

Resumen de resultados

Protocolo	Accuracy	F1 macro	Clips de prueba
A: actores no vistos	43.3 %	0.416	240
B: división al azar	60.4 %	0.599	144
Azar (8 clases)	12.5 %	—	—

- En ambos casos el modelo **supera claramente al azar**.
- La brecha A–B cuantifica cuánto se apoya el modelo en **conocer al hablante**.

Discusión: decisiones, éxito y limitaciones

¿Por qué estas decisiones?

- Recorte de 2.5 s: la mitad del clip es silencio.
- MFCC, ZCR y RMS: el EDA mostró que describen la activación.
- Dividir antes de aumentar: evita la fuga de la referencia.
- Protocolo A: el hablante domina sobre la emoción.

¿A qué se debe el resultado?

- **Éxito:** 43 % en voces nuevas vs. 12.5 % del azar.
- **Sobreajuste:** entrenamiento llega a 1.0 y validación se queda en $\approx$ 0.4–0.5.
- Solo 24 actores: el modelo memoriza voces.
- **Confusiones:** tristeza $\rightarrow$ calma, miedo y sorpresa $\rightarrow$ alegría.
- En B, las 2 repeticiones de una misma actuación pueden caer en lados distintos.

Conclusiones y sugerencias de mejora

Conclusiones

1. Sí hay señal emocional aprendible, pero **no generaliza bien** a hablantes nuevos con 24 actores.
2. La cifra de la referencia ($\approx 90\,\%$) está inflada por mezclar 4 corpus y aumentar antes de dividir.
3. Reportar A y B juntos da una imagen honesta del desempeño.

Sugerencias

- Más corpus y más actores (CREMA-D, TESS, SAVEE).
- Normalización por hablante y validación cruzada por actor.
- Entrenar con GPU y la red de ancho completo; probar espectrogramas o modelos preentrenados.
- Guardar también el `StandardScaler` para poder predecir audios nuevos.

Referencias

- S. R. Livingstone y F. A. Russo (2018). The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS). *PLoS ONE* 13(5): e0196391. Licencia CC BY-NC-SA 4.0.
- B. McFee et al. (2015). librosa: Audio and music signal analysis in Python. *Proc. SciPy*.
- gemmin. *Speech Emotion Recognition 90 %*. Kaggle Notebook.